ĐỒ ÁN HỌC PHẦN

NHẬP MÔN DỮ LIỆU LỚN

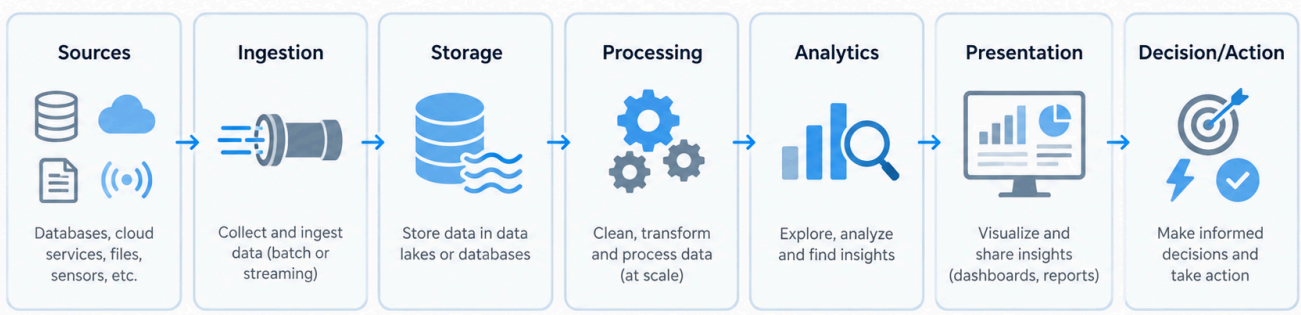
1. Mục tiêu của đồ án

Đồ án giúp sinh viên vận dụng các kiến thức của học phần Big Data để thiết kế và triển khai một phần của quy trình xử lý dữ liệu lớn. Trọng tâm không chỉ là sử dụng một công cụ cụ thể, mà là hiểu vai trò của từng thành phần trong hệ thống, xác định đúng đầu vào/đầu ra, lựa chọn công nghệ phù hợp và chứng minh quy trình có thể hoạt động trên dữ liệu có đặc trưng dữ liệu lớn.

- Nhận diện đặc trưng của bài toán dữ liệu lớn (ví dụ: Volume, Velocity, Variety, Veracity, Value) và giải thích nhu cầu xử lý phân tán hoặc xử lý ở quy mô lớn.
- Thiết kế luồng dữ liệu từ nguồn đến kết quả sử dụng, chỉ rõ các thành phần và giao diện dữ liệu giữa các bước.
- Áp dụng phù hợp các nội dung của học phần như Hadoop/MapReduce, HDFS hoặc Data Lake, Spark/PySpark, streaming, phân tích dữ liệu, graph computing và trực quan hóa.
- Thực hiện thí nghiệm hoặc demo có số liệu, log, ảnh chụp hoặc dashboard để chứng minh quy trình hoạt động.
- Rèn luyện kỹ năng làm việc nhóm, phân chia nhiệm vụ, tài liệu hóa hệ thống và trình bày kết quả kỹ thuật.

Định hướng quan trọng: Đồ án được đánh giá theo khả năng giải thích, thiết kế, triển khai và kiểm chứng. Việc chỉ chạy được một notebook hoặc sao chép một pipeline có sẵn nhưng không giải thích được luồng dữ liệu, lựa chọn công nghệ và kết quả sẽ không đáp ứng yêu cầu.

2. Mô hình tổng quát của quy trình xử lý dữ liệu lớn



Hình 1. Pipeline tổng quát của đồ án Big Data

Giai đoạn	Vai trò
Sources	Nguồn phát sinh dữ liệu: cơ sở dữ liệu, hệ thống web/app, tệp log, cảm biến/IoT, API, dữ liệu đám mây, tệp CSV/JSON/Parquet, v.v.
Ingestion	Thu thập và đưa dữ liệu vào hệ thống theo lô (batch) hoặc theo luồng (streaming).
Storage	Tổ chức lưu trữ dữ liệu có khả năng mở rộng, có thể dưới dạng Data Lake, hệ thống tệp phân tán hoặc cơ sở dữ liệu phân tán/NoSQL.
Processing	Làm sạch, chuẩn hóa, chuyển đổi, kết hợp, tổng hợp hoặc tính toán dữ liệu ở quy mô lớn.
Analytics	Khai phá và phân tích dữ liệu: truy vấn, thống kê, clustering, classification, graph analytics hoặc các kỹ thuật phù hợp.
Presentation	Trực quan hóa và cung cấp kết quả dưới dạng dashboard, báo cáo, biểu đồ hoặc API phục vụ người dùng nghiệp vụ.
Decision / Action	Chuyển insight/KPI thành quyết định hoặc hành động như cảnh báo, khuyến nghị, kích hoạt API, gửi thông báo hoặc điều chỉnh nghiệp vụ.

3. Tổ chức nhóm và phạm vi thực hiện

- Mỗi nhóm gồm tối đa 05 thành viên.
- Mỗi nhóm chọn 01 quy trình con trong danh sách ở Mục 4. Nhóm có thể đề xuất quy trình khác nếu vẫn thuộc pipeline và được giảng viên chấp thuận.
- Khuyến khích các nhóm phối hợp để đầu ra của nhóm trước trở thành đầu vào của nhóm sau, từ đó hình thành một pipeline hoàn chỉnh.
- Mỗi nhóm vẫn phải có sản phẩm độc lập có thể đánh giá được; không được phụ thuộc hoàn toàn vào tiến độ của nhóm khác.

4. Danh sách quy trình và bài toán gợi ý

Quy trình	Bài toán gợi ý	Công nghệ gợi ý	Sản phẩm tối thiểu
Sources → Ingestion	Thu thập dữ liệu hành vi người dùng và giao dịch từ website/app theo thời gian thực.	Python Producer, Apache Kafka, REST API	Producer/API sinh hoặc thu thập dữ liệu; topic/queue nhận dữ liệu; log chứng minh tốc độ và tính liên tục.
Ingestion → Storage	Nhận dữ liệu từ hệ thống ingestion và tổ chức lưu trữ vào Data Lake.	Kafka Connect, HDFS, MinIO/S3, Parquet, Delta Lake	Dữ liệu được phân vùng/lưu đúng schema; mô tả partition; truy xuất được dữ liệu đã lưu.
Storage → Processing	Làm sạch, chuẩn hóa, kết hợp và tổng hợp dữ liệu lớn.	Apache Spark, PySpark, Spark SQL	Job xử lý phân tán; dữ liệu trước/sau xử lý; thống kê chất lượng và thời gian xử lý.
Processing → Analytics	Phân tích doanh thu, hành vi khách hàng, hiệu quả sản phẩm hoặc dữ liệu lĩnh vực khác.	Spark SQL, PySpark, Python	Bộ truy vấn/KPI hoặc mô hình phân tích; kết quả có số liệu và diễn giải.
Analytics → Presentation	Trình bày kết quả phân tích để người dùng nghiệp vụ theo dõi và khai thác.	Power BI, Tableau, Apache Superset, Grafana	Dashboard/báo cáo có KPI, bộ lọc, biểu đồ và nguồn dữ liệu rõ ràng.
Presentation → Decision / Action	Dựa trên dashboard/KPI để đưa ra quyết định và kích hoạt hành động.	Python Rule Engine, FastAPI, Webhook, Email/Telegram API	Luật hoặc API ra quyết định; demo một hoặc nhiều hành động được kích hoạt từ dữ liệu/KPI.

4.1. Một số miền dữ liệu có thể lựa chọn

Sinh viên có thể chọn dữ liệu thương mại điện tử, giao thông, IoT/cảm biến, mạng xã hội, log hệ thống, giáo dục, tài chính mô phỏng, dữ liệu công khai hoặc một lĩnh vực phù hợp khác. Điểm quan trọng là bài toán phải thể hiện rõ lý do cần kiến trúc Big Data, không chỉ là phân tích một tệp nhỏ bằng Python/Pandas.

5. Yêu cầu bắt buộc đối với mỗi nhóm

5.1. Quy trình được lựa chọn

Nêu rõ nhóm phụ trách giai đoạn nào trong pipeline, ranh giới bắt đầu/kết thúc và quan hệ với các giai đoạn trước/sau.

5.2. Bài toán cụ thể và tính chất dữ liệu lớn

Mô tả bài toán thực tế và trả lời: vì sao bài toán cần tiếp cận Big Data? Nhóm phải chỉ ra ít nhất 02 đặc trưng phù hợp trong Volume, Velocity, Variety, Veracity hoặc nhu cầu xử lý phân tán/mở rộng.

5.3. Input

Mô tả nguồn dữ liệu, cách thu thập, định dạng, schema, số lượng bản ghi/khối lượng dữ liệu, tốc độ phát sinh (nếu có), các trường dữ liệu chính và ví dụ bản ghi.

5.4. Output

Mô tả chính xác kết quả đầu ra: dữ liệu đã lưu, bảng dữ liệu đã xử lý, KPI, mô hình, dashboard, API hoặc hành động. Nêu định dạng và ví dụ đầu ra.

5.5. Công nghệ sử dụng

Liệt kê từng công nghệ và giải thích vai trò. Không chấp nhận chỉ liệt kê tên công cụ mà không mô tả lý do lựa chọn và vị trí trong kiến trúc.

5.6. Sơ đồ luồng xử lý

Có sơ đồ kiến trúc hoặc data-flow từ input đến output, thể hiện thành phần, luồng dữ liệu, giao thức/định dạng chính và nơi xử lý/lưu trữ.

5.7. Kết quả demo/thực nghiệm

Có bằng chứng quy trình hoạt động: log, ảnh chụp, dashboard, dữ liệu trước/sau, số liệu throughput/latency/thời gian xử lý, kết quả truy vấn hoặc kết quả phân tích phù hợp.

5.8. Khả năng tái lập

Nộp mã nguồn/cấu hình cần thiết, hướng dẫn chạy, yêu cầu môi trường và dữ liệu mẫu hoặc script sinh dữ liệu để người khác có thể kiểm tra.

6. Báo cáo đồ án - đánh giá giữa kỳ

Báo cáo cuối kỳ phải thể hiện những gì nhóm đã thực sự triển khai và kiểm chứng, không chỉ mô tả ý tưởng. Khuyến nghị độ dài 30 trang A4, không tính trang bìa, mục lục, tài liệu tham khảo và phụ lục.

6.1. Cấu trúc báo cáo cuối kỳ

Trang bìa và thông tin nhóm: Tên đề tài, học phần, lớp, thành viên, phân công thực tế.

Tóm tắt: Khoảng 150-250 từ: bài toán, pipeline, công nghệ, dữ liệu, kết quả nổi bật.

1. Giới thiệu: Bối cảnh, mục tiêu, phạm vi, câu hỏi kỹ thuật cần giải quyết.

2. Cơ sở và công nghệ liên quan: Kiến thức Big Data liên quan trực tiếp; chỉ trình bày phần cần dùng cho đồ án.

3. Dữ liệu và yêu cầu: Nguồn, schema, quy mô, đặc trưng Big Data, input/output, data contract nếu có.
4. Thiết kế hệ thống: Kiến trúc, sơ đồ data-flow, giải thích lựa chọn công nghệ và cấu hình chính.
5. Cài đặt và triển khai: Môi trường, thành phần, cấu hình, xử lý lỗi, cách chạy các job/service.
6. Thực nghiệm và đánh giá: Kịch bản thí nghiệm, dữ liệu thử nghiệm, tiêu chí đánh giá, kết quả đo và phân tích.
7. Kết quả demo: Ảnh chụp/log/dashboard hoặc kết quả API; mô tả luồng demo từ input đến output.
8. Thảo luận: Điểm mạnh, hạn chế, bài học kỹ thuật, vấn đề gặp phải và hướng cải tiến.
9. Kết luận: Mức độ đạt mục tiêu; kết quả chính; khả năng tích hợp với các giai đoạn khác.
Tài liệu tham khảo: Trích dẫn tài liệu đã sử dụng, ưu tiên tài liệu chính thức và nguồn học thuật.
Phụ lục: Hướng dẫn chạy, cấu hình, schema, API, đường dẫn mã nguồn, bảng phân công/đóng góp.

6.2. Thang điểm báo cáo giữa kỳ (10 điểm)

Tiêu chí	Điểm	Mô tả
Mức độ hoàn thành hệ thống theo phạm vi đã chọn	2.5	Pipeline hoạt động, thành phần kết nối đúng, đầu ra phù hợp yêu cầu.
Thiết kế và triển khai kỹ thuật	2.0	Kiến trúc hợp lý; cấu hình và mã nguồn có tổ chức; xử lý dữ liệu đúng.
Thực nghiệm và bằng chứng hoạt động	2.0	Có demo/log/số liệu; kịch bản kiểm thử đủ rõ để kiểm chứng.
Thể hiện đặc trưng Big Data và khả năng mở rộng	1.5	Có dữ liệu/tải phù hợp; thí nghiệm hoặc lập luận về scale/stream/distribution thuyết phục.
Phân tích kết quả và thảo luận	1.0	Giải thích số liệu, nhận diện hạn chế, rút ra bài học kỹ thuật.
Chất lượng báo cáo và khả năng tái lập	1.0	Báo cáo rõ, trích dẫn phù hợp, có hướng dẫn chạy/mã nguồn/cấu hình và phân công đóng góp.

7. Minh chứng cần nộp

- Báo cáo giữa kỳ: file PDF theo cấu trúc Mục 6.
- Mã nguồn và cấu hình: repository hoặc file nén, có README hướng dẫn cài đặt và chạy.

- Dữ liệu: đường dẫn nguồn dữ liệu, dữ liệu mẫu hoặc script sinh dữ liệu; không bắt buộc nộp toàn bộ dữ liệu lớn nếu dung lượng quá lớn.
- Minh chứng demo: ảnh chụp, log, dashboard, kết quả API hoặc video ngắn nếu cần để chứng minh hệ thống đã chạy.
- Bảng phân công và đóng góp của từng thành viên.

8. Quy định về công cụ AI và tính trung thực học thuật

Sinh viên được phép sử dụng AI tạo sinh như một công cụ hỗ trợ học tập và phát triển, ví dụ để giải thích tài liệu, gợi ý cấu trúc mã, hỗ trợ debug hoặc cải thiện cách trình bày. Tuy nhiên, nhóm chịu trách nhiệm hoàn toàn về nội dung nộp và phải hiểu được hệ thống của mình.

- Không nộp mã nguồn, sơ đồ hoặc báo cáo do AI sinh ra mà nhóm không thể giải thích.
- Các quyết định kỹ thuật quan trọng phải có lập luận của nhóm: vì sao chọn công nghệ, cấu hình, schema và cách đánh giá.
- Nếu AI được sử dụng đáng kể để tạo mã hoặc nội dung, nên ghi ngắn gọn trong phụ lục: công cụ, mục đích sử dụng và phần nào đã được nhóm kiểm tra/chỉnh sửa.